Banka Müşteri Kaybı Analizi

Sınırlı kapasiteyle hangi müşterilere öncelik verilmeli?

Staj projesi raporu · Ekim 2026

Hazırlayan: Göktürk Ünal

Özet

Bu projede bir bankanın müşteri verisiyle şu soruya cevap aramaya çalıştım: Müşteri tutma ekibi herkesi arayamıyorsa, bankadan ayrılacak müşterilerin olabildiğince çoğuna ulaşmak için öncelikle kimleri aramalı?

Elimdeki veri 10.000 müşteriden oluşuyordu ve bu müşterilerin yaklaşık beşte biri (%20,4) bankadan ayrılmıştı. Önce veriyi SQL Server'da kontrol ettim, sonra Python ile hangi müşteri gruplarında ayrılmanın yoğunlaştığına baktım. Bu incelemeden yaş, ürün sayısı ve ülkeye dayanan basit bir öncelik kuralı çıktı. Ardından bir makine öğrenmesi modeli kurdum ve modeli bu basit kuralla, daha önce hiç görmediği 1.501 müşteri üzerinde karşılaştırdım. Son olarak sonuçları Power BI'da ekibin kendi varsayımlarını girip deneyebileceği bir panele dönüştürdüm.

Vardığım sonuçlar kısaca şöyle:

- Ayrılma birkaç grupta yoğunlaşıyor. 40–59 yaş arasındaki müşteriler tüm müşterilerin yaklaşık üçte biri, ama ayrılanların üçte ikisi. Üç veya daha fazla ürünü olan müşterilerin büyük çoğunluğu ve Almanya'daki müşterilerin yaklaşık üçte biri ayrılmış.
- Ekip en riskli %20'yi (bu test grubunda 300 kişi) ararsa, model ayrılanların %61'ini, basit kural ise %59'unu yakalıyor. Aradaki fark küçük ve istatistiksel olarak belirgin değil. Model ise sıralamanın genelinde daha iyi ve "listede kaç kişi ayrılır" sorusuna tutarlı cevap veriyor.
- Hangi yöntem kullanılırsa kullanılsın genç müşteriler (18–39 yaş) listede az yer alıyor. Ayrıca daha fazla müşteri aramak her zaman daha kârlı değil; kapasite, maliyet ve teklifin başarısına göre verilmesi gereken bir iş kararı.

En önemli sınır şu: Veride ne tarih ne de teklif bilgisi var. Bu yüzden bu çalışma kimin ne zaman ayrılacağını ya da bir teklifin gerçekten işe yarayıp yaramadığını söyleyemez. Bu nedenle ilk önerim, kampanyayı yaygınlaştırmadan önce küçük ve kontrollü bir pilot deney yapmak.

1. Neden bu soruyu sordum?

Müşteri kaybı projelerinde ilk akla gelen soru genellikle "kim ayrılacak?" oluyor. Ama bir müşteri tutma ekibinin gerçek sorunu biraz farklı: Ekibin zamanı ve bütçesi sınırlı, yani herkesi arayamıyor. Asıl karar, sınırlı sayıdaki aramanın kime yapılacağı.

Bu yüzden projeyi bir tahmin probleminden çok bir önceliklendirme problemi olarak ele aldım. Ekibin kaç kişiyi arayabileceğini bilmediğim için sonuçları farklı kapasitelerle (müşterilerin %10'u, %20'si, %30'u gibi) inceledim. Ana karşılaştırma noktası olarak %20'yi seçtim ve bunu son testten önce sabitledim.

Başarıyı nasıl ölçeceğim konusunda da baştan bir karar vermem gerekti. Müşterilerin yaklaşık %80'i zaten kaldığı için, "kimse ayrılmayacak" diyen bir tahmin bile %80 doğruluğa ulaşır ama hiçbir ayrılan müşteriyi bulamaz. Bu yüzden doğruluk (accuracy) oranını kullanmadım. Onun yerine şu sorulara baktım:

- En riskli %20'ye bakıldığında ayrılanların yüzde kaçı listede? (ana iş ölçütü)
- Model müşterileri genel olarak ne kadar iyi sıralıyor? (Average Precision)
- Modelin "bu listede şu kadar kişi ayrılacak" tahmini gerçeğe ne kadar yakın?

Bir modeli tek başına değerlendirmek de yeterli değildi. Modelin gerçekten bir şey kattığını görmek için onu iki basit yaklaşımla karşılaştırdım: tamamen rastgele bir liste ve veri incelemesinden çıkardığım basit bir segment kuralı. Model bu kuralı geçemiyorsa, karmaşık bir model kullanmanın anlamı olmazdı.

2. Veriyi tanımak

Projede Kaggle'da yayımlanan "Churn Modelling" veri setini kullandım. Veri 10.000 müşteriden ve 14 alandan oluşuyor: yaş, cinsiyet, ülke (Fransa, Almanya, İspanya), banka ile ilişki süresi, bakiye, ürün sayısı, kredi kartı, aktif üyelik, kredi puanı, tahmini maaş ve müşterinin ayrılıp ayrılmadığı. Müşterilerin 2.037'si (%20,4) ayrılmış.

Analize başlamadan önce veriyi SQL Server'a yükleyip kalitesini kontrol ettim. Her müşteri kimliği tekti, hiçbir alanda eksik değer yoktu, evet/hayır alanları yalnızca 0 ve 1 içeriyordu ve tekrarlanan kayıt bulunmadı. Bulduğum tek sorun, 92 müşterinin soyadında bozuk karakterlerdi. Soyadını analizde kullanmadığım için bunun sonuçlara bir etkisi olmadı. Hiçbir kaydı silmedim veya değiştirmedim; uç değerleri işaretleyip veride bıraktım.

Veriyi incelerken bazı önemli eksiklikleri de fark ettim ve bunları baştan not etmenin doğru olacağını düşündüm:

- **Tarih bilgisi yok.** Müşterinin ne zaman ayrıldığını bilmiyorum. Bu yüzden "30 gün içinde ayrılacak" gibi bir tahmin yapmadım; yalnızca riske göre sıralama yaptım.
- **Teklif veya kampanya bilgisi yok.** Bir teklifin müşteriyi tutup tutmadığını gösteren hiçbir kayıt yok. Bu nedenle kampanyaya dair bütün hesaplar varsayıma dayanıyor.
- **Bazı tanımlar belirsiz.** Ayrılmanın nasıl tanımlandığı, para birimi ve "aktif üye"nin ne anlama geldiği belgelenmemiş.
- **"Aktif üye" bilgisi yanıltıcı olabilir.** Bir müşteri ayrılmadan önce zaten pasif hale gelmiş olabilir. Bu durumda bu bilgi ayrılmanın bir nedeni değil, bir belirtisi olur. Modelin, gerçek hayatta elimizde olmayacak bir bilgiye dayanmasını istemediğim için ana modelde bu alanı kullanmadım.
- **Verinin kaynağı belli değil.** Bazı dağılımlar verinin yapay olarak üretilmiş olabileceğini düşündürüyor. Bu yüzden bulguları gerçek bir bankaya genellemek yerine "bu veri setinde gördüklerim" olarak sunuyorum.

Model aşamasına geçmeden önce müşterileri üç gruba ayırdım: modeli kurmak için 7.000 müşteri, model ve ayar seçmek için 1.499 müşteri ve sonuçları en sonda tek bir kez ölçmek için 1.501 müşteri. Bu son gruba bütün kararlar verildikten sonra baktım. Raporda modelle ilgili bütün sonuçlar bu 1.501 müşteriden geliyor.

3. Veride ne gördüm?

İlk incelemeyi 10.000 müşterinin tamamında yaptım. Her grup için yalnızca ayrılma oranına değil, o oranın kaç müşteriye dayandığına da baktım. Küçük gruplarda oranlar çok oynak olabildiği için her oranın yanına bir güven aralığı ekledim.

En belirgin iki değişken yaş ve ürün sayısı oldu. Yaşla ayrılma arasındaki ilişki düz bir çizgi değil: Ayrılma oranı yaşla birlikte artıyor, 50–59 yaşta %56'ya çıkıyor, 70 yaşın üstünde ise %10'a düşüyor. 40–59 yaş arasındaki müşteriler tüm müşterilerin %35'i, ama ayrılanların %64'ü bu grupta.

Ürün sayısında da ilginç bir tablo var. En az ayrılan grup iki ürünü olanlar (%7,6). Tek ürünü olanlarda oran %27,7'ye çıkıyor. Üç veya daha fazla ürünü olan 326 müşterinin ise %85,9'u ayrılmış. Bu küçük ama çok yoğun bir risk grubu.

Ülkelere bakınca Almanya öne çıkıyor. Almanya'daki müşterilerin %32,4'ü ayrılmış; Almanya tüm müşterilerin dörtte biri, ama ayrılanların %40'ı. Aktif olmayan üyelerde (%26,9), kadın müşterilerde (%25,1) ve bakiyesi olan müşterilerde de ayrılma daha yüksek. Banka ile ilişki süresi, kredi puanı ve maaş ise tek başına ayrılanlarla kalanları neredeyse hiç ayırmıyor.

Bu aşamada dikkat etmem gereken bir nokta da değişkenlerin birbirini etkilemesiydi. Örneğin Almanya'da bakiyesi sıfır olan hiç müşteri yok. Bu yüzden "Almanya'da ayrılma yüksek" ile "bakiyesi olanlarda ayrılma yüksek" bulgularını birbirinden bağımsız okumamak gerekiyor.

Bu bulgulardan yola çıkarak basit bir öncelik kuralı oluşturdum. Müşterileri yaş, ürün sayısı, ülke ve aktifliğe göre, her biri en az 100 kişiden oluşan 24 gruba ayırdım ve grupları ayrılma oranlarına göre sıraladım. Bu

kurala göre en riskli %20'ye bakıldığında ayrılanların %57,5'i yakalanıyordu. Bu sonuç aynı veride hem kurulup hem ölçüldüğü için olduğundan iyi görünüyor olabilir; asıl karşılaştırmayı bir sonraki bölümde, modelin görmediği müşterilerde yaptım.

4. Basit bir kural mı, bir model mi?

Model için üç farklı yöntem denedim: Random Forest, lojistik regresyon ve gradient boosting. Lojistik regresyonda veri incelemesinden öğrendiklerimi kullandım; örneğin yaşın ters U biçimindeki ilişkisini ve ürün sayısıyla bakiye arasındaki etkileşimi modele ekledim. Ayrılanlar azınlıkta olduğu için bu dengesizliği düzeltmeye yönelik iki yöntemi de denedim. Bu yöntemler sıralamayı iyileştirmedi ve olasılık tahminlerini bozdu, bu yüzden kullanmadım.

Üç yöntem birbirine çok yakın sonuçlar verdi. Aralarından seçim yapmak için önceden bir kural belirledim: en iyi sonuca çok yakın olanlar arasından en sade modeli seç. Bu kural Random Forest'ı seçti. Modelin en riskli müşterilerin riskini olduğundan düşük gösterdiğini fark ettiğim için olasılıklarını kalibrasyonla düzelttim. Bütün bu kararları test verisine bakmadan, eğitim ve geliştirme verisiyle verdim.

Son testte, yani modelin hiç görmediği 1.501 müşteride (306 ayrılan), sonuçlar şöyle çıktı:

Yöntem	En riskli %20'de yakalanan ayrılan	Listedekilerin ayrılma oranı	Genel sıralama kalitesi (AP)
Model (Random Forest)	%61,1 (aralık %56,5–65,6)	%62,3	0,675
Basit segment kuralı	%58,7 (aralık %54,6–63,1)	%59,9	0,589
Rastgele seçim	%20,0	%20,4	0,204

Bu sonuçları şöyle yorumluyorum:

İki yöntem de rastgele seçimden çok daha iyi; rastgele bir liste ayrılanların yalnızca beşte birini yakalıyor. En riskli 300 kişiye bakıldığında ise model ile basit kural arasındaki fark 2,4 puan. Güven aralığı sıfırı içerdiği için bu farkın gerçek bir fark olduğunu söyleyemem. Yani ekip yalnızca %20'ye bakacaksa, basit kural neredeyse aynı işi görüyor.

Modelin asıl farkı iki yerde ortaya çıkıyor. Birincisi, müşterileri genel olarak daha iyi sıralıyor (AP farkı belirgin). Bu da ekibin kapasitesi değiştiğinde modelin daha güvenilir olacağı anlamına geliyor. İkincisi, modelin tahminleri gerçeğe çok yakın: En riskli 300 kişide 187 kişinin ayrılmasını bekliyordu ve gerçekten 187 kişi ayrılmıştı. Bu, bütçe planlarken "listede kaç kişi ayrılacak" sorusuna güvenilir bir cevap veriyor.

Denediğim diğer iki model (gradient boosting ve lojistik regresyon) testte Random Forest'a çok yakın, hatta biraz daha iyi sonuç verdi. Ancak model seçimini testten önce yapmıştım ve test sonucuna göre modeli değiştirmedim. Aksi halde test verisini de seçim için kullanmış olurdum.

"Aktif üye" bilgisini kullanan bir model sürümü de denedim. Bu sürüm daha iyi sonuç verdi (%62,7). Ama bu bilginin ne zaman ölçüldüğünü bilmediğim için onu ana model yapmadım; yalnızca "bu bilgi güvenilirse ulaşılabilecek düzey" olarak not ettim. Model en çok ürün sayısı ve yaşa dayanıyor, ardından ülke ve bakiye geliyor. Bu sıralama hangi bilgilerin işe yaradığını gösteriyor, ama müşterilerin neden ayrıldığını açıklamıyor.

Sonuçların tekrar üretilebildiğinden emin olmak için model çalışmasının tamamını sonradan ayrı bir ortamda baştan yeniden çalıştırdım; veri ayrımı, seçilen model ve test sonuçları birebir aynı çıktı.

5. Kaç müşteriyi aramalı?

Bu bölüm projenin bana göre en "iş" tarafı. Bir model ne kadar iyi olursa olsun, kampanyanın kâr edip etmeyeceği maliyete ve teklifin ne kadar işe yaradığına bağlı. Veride bu bilgiler olmadığı için Power BI'da, ekibin kendi varsayımlarını girerek sonucu görebileceği bir senaryo sayfası hazırladım.

Hesabın mantığı basit:

- Teklif, listedeki herkese gidiyor. Bu yüzden maliyet, listedeki müşteri sayısı ile müşteri başına teklif maliyetinin çarpımı.
- Kazanç ise yalnızca gerçekten ayrılacak olan ve teklif sayesinde kalan müşterilerden geliyor.
- Net fayda, kazançtan maliyetin çıkarılmasıyla bulunuyor.

Örnek olarak şu varsayımları kullandım: teklif ayrılacak müşterilerin %20'sini tutuyor, teklifin müşteri başına maliyeti 50, tutulan bir müşterinin değeri 500. Bu rakamlar gerçek değil; yalnızca hesabın nasıl çalıştığını göstermek için seçildi ve para birimi yok. Bu varsayımlarla en riskli %20 aranırsa model listesiyle kampanya +3.700, basit kuralla +2.970 net fayda sağlıyor; rastgele bir liste ise −8.884 zarar ediyor.

Bu hesaptan çıkan en faydalı bilgi bence "başabaş noktası" oldu. Model listesiyle yapılan bir kampanyanın zarar etmemesi için teklifin, listedeki ayrılacak müşterilerin en az %16'sını tutması gerekiyor. Rastgele bir listede bu oran %49'a çıkıyor. Doğru müşteriyi seçmenin değeri tam olarak burada görülüyor.

Kapasiteyi değiştirdiğimde ise beklemediğim bir sonuç çıktı:

Aranan müşteri payı	Aranan kişi	Yakalanan ayrılan	Net fayda
%10	150	119	+4.400
%15	225	159	+4.650
%20	300	187	+3.700
%30	450	226	+100
%50	750	269	−10.600

Daha fazla müşteri aramak daha fazla ayrılanı yakalıyor, ama listeye giren ve aslında ayrılmayacak olan müşteri sayısı çok daha hızlı artıyor. %50'de listedeki 750 kişinin 481'i zaten kalacak müşteriler. Bu varsayımlarla en yüksek kâr %10–15 civarında elde ediliyor.

Bu sonucu kesin bir öneri olarak görmüyorum, çünkü tamamen varsayımlara bağlı. Tutulan bir müşterinin değeri daha yüksekse en kârlı kapasite de büyür. Benim çıkardığım ders şu oldu: Kaç kişinin aranacağı bir modelin değil, bir iş kararının konusu. Model yalnızca bu kararı verirken kullanılacak bilgiyi sağlıyor.

6. Listede kimler yok?

Bir modelin genel başarısı, bazı müşteri gruplarını sistematik olarak gözden kaçırdığını gizleyebilir. Bu yüzden en riskli 300 kişilik listede her gruptan ayrılanların ne kadarının yer aldığına baktım:

Grup	Ayrılan	Listede yer alan	Yakalanan payı
Kadın	167	102	%61
Erkek	139	85	%61
Fransa	134	69	%52
Almanya	115	90	%78
İspanya	57	28	%49
18–39 yaş	79	16	%20
40–49 yaş	125	91	%73
50–59 yaş	79	66	%84
60–69 yaş	21	14	%67
70 yaş ve üstü	2	0	%0

En dikkat çekici sonuç genç müşterilerde. 18–39 yaş arasında ayrılan 79 müşteriden yalnızca 16'sı listede. Bu grupta ayrılma oranı genel olarak düşük olduğu için model gençlere öncelik vermiyor. Buna karşılık liste büyük ölçüde orta yaşlı ve Almanya'daki müşterilerden oluşuyor; 300 aramanın 141'i Almanya'ya gidiyor. Kadın ve erkek müşteriler arasında belirgin bir fark görmedim. Cinsiyeti modelde zaten kullanmamıştım. 70 yaş üstünde yalnızca 2 ayrılan olduğu için o grup hakkında bir şey söylemek mümkün değil.

Gençleri yakalamak için kapasiteyi artırmayı da denedim. Kapasite %50'ye çıktığında genç ayrılanların %62'si listeye giriyor, ama listedeki 253 gencin yalnızca 49'u gerçekten ayrılıyor. Bir başka seçenek gençler için ayrı bir liste hazırlamak: Yalnızca genç müşterilerin en riskli %20'sine (181 kişi) bakıldığında 79 genç ayrılandan 43'ü yakalanıyor, ama listedeki 138 kişi zaten kalacak müşteriler.

Bu iki rakam aslında iki farklı soruya cevap veriyor. Birincisi "tek bir ortak kampanya yaparsak gençler ne kadar temsil edilir?", ikincisi "gençlere ayrı bir bütçe ayırırsak ne olur?". Hangisinin doğru olduğuna karar vermek bana değil, genç müşteri kaybının banka için ne kadar öncelikli olduğuna bağlı.

7. Bu çalışma neyi söyleyebilir, neyi söyleyemez?

Bu proje boyunca en çok dikkat ettiğim şeylerden biri, verinin söylemediği şeyleri sonuç gibi sunmamaktı.

Bu çalışma müşterileri ayrılma riskine göre sıralayabilir, belirli bir kapasitede kimin listeye gireceğini ve listede kaç kişinin ayrılacağını tahmin edebilir. Farklı maliyet varsayımlarıyla kampanyanın ne zaman kâra geçeceğini gösterebilir ve hangi grupların listede az temsil edildiğini ortaya koyabilir.

Buna karşılık bir müşterinin ne zaman ayrılacağını söyleyemez, çünkü veride tarih yok. Bir teklife kimin olumlu yanıt vereceğini bilemez; ayrılma riski yüksek olmak, teklifle ikna olacağı anlamına gelmez. Müşterilerin neden ayrıldığını da açıklayamaz; gördüğüm ilişkiler neden-sonuç ilişkisi değil. Sonuçlar bu veri setine ait ve gerçek bir bankanın müşterilerine doğrudan taşınamaz. Son olarak, ilk incelemeyi tüm veride yaptığım için test sonuçları o incelemeden tamamen bağımsız değil. Model seçimini test verisine bakmadan yaptım, ama bu sınırı belirtmem gerektiğini düşünüyorum.

8. Önerilerim

Önce küçük bir pilot deney yapılmalı. Kampanyanın kâr edip etmeyeceği tamamen teklifin gerçek etkisine bağlı ve bu etkiyi bilmiyoruz. Bir sonraki bölümde bunun nasıl ölçülebileceğini anlattım.

Model mi kural mı sorusu ihtiyaca göre cevaplanmalı. Ekip her zaman yaklaşık %20'lik bir kapasiteyle çalışacaksa, kolayca anlaşılıp anlatılabilen basit kural yeterli olabilir. Kapasite dönemden döneme değişiyorsa ya da bütçe planlamasında "kaç kişi ayrılacak" tahmini önemliyse model daha uygun.

Kapasite gerçek maliyet ve değer bilgisiyle belirlenmeli. Örnek varsayımlarla en kârlı aralık %10–15 çıktı, ama bu sonuç gerçek rakamlarla değişebilir. Kampanya ekibi kendi rakamlarını panele girerek bunu hemen görebilir.

Genç müşteriler için ayrı bir karar verilmeli. Genel liste bu grubu büyük ölçüde dışarıda bırakıyor. Genç müşteri kaybı bir öncelikse, bu gruba farklı bir yaklaşım gerekip gerekmediği değerlendirilmeli. Bu raporun ayrı bir yaklaşımın işe yarayacağını göstermediğini, yalnızca genel listenin bu grup için uygun olmadığını gösterdiğini belirtmeliyim.

"Aktif üye" bilgisinin ne zaman ölçüldüğü öğrenilmeli. Bu bilgi müşteri ayrılmadan önce ölçülüyorsa, modele eklenmesi sonuçları biraz iyileştirebilir.

9. Teklifin işe yarayıp yaramadığını nasıl ölçeriz?

Geçmiş veriye bakarak teklifin etkisini ölçmek yanıltıcı olur, çünkü teklifler genellikle zaten riskli görülen müşterilere verilir. Bu yüzden önerim kontrollü bir deney, yani bir A/B testi.

Fikir basit: En riskli müşteri listesi rastgele iki gruba ayrılır. Bir gruba teklif verilir, diğerine verilmez. Belirli bir süre sonunda iki grubun ayrılma oranları karşılaştırılır. Gruplar rastgele oluşturulduğu için aradaki tek fark teklif olur ve gözlenen fark teklifin etkisi olarak okunabilir. Grupların dengeli olması için atamayı risk dilimi ve ülke içinde ayrı ayrı yapmak iyi olur. Teklif grubuna atanan herkes, teklifi kabul etmese bile bu grupta sayılmalı. Gözlem süresine banka karar vermeli; veride tarih olmadığı için bu konuda bir öneri yapamıyorum. Önemli olan sürenin deneye başlamadan önce belirlenmesi.

Deneyin kaç müşteriyle yapılması gerektiğini de hesapladım. Test grubundaki en riskli %20'nin yaklaşık %62'si ayrılmıştı. Kampanyanın zarar etmemesi için teklifin bu müşterilerin en az %16'sını tutması

gerekiyordu; bu da ayrılma oranının yaklaşık %62'den %52'ye düşmesi demek. Bu farkı güvenilir biçimde görebilmek için her grupta yaklaşık 385, toplamda yaklaşık 770 müşteri gerekiyor:

Teklifin tuttuğu ayrılan payı	Grup başına gereken müşteri	Toplam
%10	975	1.950
%16 (başabaş noktası)	385	770
%20	248	496
%30	111	222

Teklif ne kadar etkiliyse o kadar az müşteriyle sonuç görülebiliyor. Etki başabaş noktasından küçükse deney onu güvenilir şekilde göremeyebilir, ama o durumda kampanya zaten kâr etmeyecektir.

Deneye başlamadan önce kararın nasıl verileceği de yazılmalı. Örneğin: Teklif grubunda ayrılma belirgin şekilde daha düşükse ve tutulan müşteri oranı başabaş noktasının üzerindeyse kampanya yaygınlaştırılır. Sonuçlara deney sırasında sık sık bakıp erken karar vermek de doğru olmaz; bu, yanlış sonuçlara yol açabilir.

Bu hesaplar varsayımlara dayanıyor ve bankanın kendi verisiyle yeniden yapılmalı. Projede bu deneyi simüle etmedim; yalnızca tasarımını öneriyorum.

10. Kampanya ekibine sormak istediklerim

Kampanya hesabındaki bazı bilgiler veride yok ve bunları ancak kampanya ekibi cevaplayabilir. Bu sorulara cevap almadan kârlılık hakkında kesin bir şey söylemek istemedim:

1. Teklifin maliyeti tam olarak nedir? Arama maliyeti ile indirim maliyeti ayrı mı, teklifi kabul etmeyen müşteri için de maliyet oluşuyor mu?
2. Teklif, zaten kalacak olan müşterilerin davranışını değiştirir mi?
3. Tutulan bir müşterinin bankaya değeri nasıl hesaplanmalı?
4. Ekip belirli bir dönemde gerçekte kaç müşteriyle iletişime geçebilir?
5. Bazı gruplar, örneğin genç müşteriler, diğerlerinden daha öncelikli mi?

Bu cevaplar Power BI'daki senaryo sayfasına girildiğinde sonuç hemen değişiyor; yani paneli bu konuşma için bir araç olarak da kullanmak mümkün.

11. Bu projeden öğrendiklerim

Bu, bu tür bir projeyi uçtan uca ilk kez yaptığım çalışma oldu. Teknik becerilerin yanında birkaç önemli şey öğrendim:

- **Doğru soruyu sormak, modelden daha önemli.** "Kim ayrılacak?" yerine "kimi önce aramalıyız?" diye sormak; ölçütleri, karşılaştırmaları ve sonuçların sunuluşunu tamamen değiştirdi.
- **Basit bir rakip olmadan bir modelin değerini anlamak zor.** Basit segment kuralı olmasaydı modelin %61'lik sonucu çok etkileyici görünebilirdi. Kuralla karşılaştırınca modelin asıl katkısının başka yerde olduğunu gördüm.
- **Belirsizliği göstermek, sonucu göstermek kadar önemli.** Küçük gruplarda tek bir oran çok yanıltıcı olabiliyor. Her oranın yanında kaç müşteriye dayandığını ve güven aralığını göstermeye çalıştım.
- **Kapasite ve kârlılık teknik değil, iş kararları.** Model bu kararlar için bilgi sağlıyor, ama kararı vermiyor.
- **Tutarlılığı kontrol etmek zaman alıyor ama gerekli.** Proje sırasında kapasite hesabının Python ve Power BI'da küçük farklarla yapıldığını fark ettim ve iki tarafı aynı kurala bağladım. Panelin bütün önemli rakamlarını Python sonuçlarıyla tek tek karşılaştırdım.

Önümüzdeki adımlar için en çok merak ettiğim şey, bir pilot deneyden gelecek veriyle "kim ayrılacak?" yerine "kim teklifle kalır?" sorusunu yanıtlayan bir model kurmak olurdu. Tarih bilgisi eklenirse müşterilerin ne zaman ayrıldığını da incelemek mümkün olur.

Ek: Yöntem notları ve dosyalar

Kullandığım araçlar: Veri yükleme, kalite kontrolleri ve özet sorgular için SQL Server; veri incelemesi ve modelleme için Python (pandas, scikit-learn, imbalanced-learn, Optuna); etkileşimli panel için Power BI.

Yöntemle ilgili birkaç not:

- Model ve ayarlar test verisine bakılmadan seçildi. Verinin dönüştürülmesiyle ilgili bütün işlemler yalnızca eğitim verisinde öğrenildi.
- Değerlendirme ölçütleri ve ana kapasite (%20) son testten önce sabitlendi.
- Grupların oranları için %95 Wilson güven aralığı, yöntemleri karşılaştırmak için aynı test müşterilerinin 2.000 kez yeniden örneklenmesi (bootstrap) kullanıldı.
- Kapasite tamsayı olarak hesaplandı (1.501 müşterinin %20'si 300 kişi); eşit skorlu müşteriler sabit bir kuralla sıralandı.
- Müşteri numarası, soyadı ve cinsiyet model girdisi olarak kullanılmadı. Cinsiyet yalnızca modelin gruplar arasındaki başarısını kontrol etmek için incelendi.
- Panelin rakamları Python ve SQL sonuçlarıyla karşılaştırıldı; kapasite hesapları için birim testleri yazıldı.

Proje dosyaları: Veri incelemesi notebooks/01_eda.ipynb, model çalışması notebooks/02_ml.ipynb, SQL sorguları sql/, panel powerbi/Churn_Analysis.pbix. Bu rapordaki ek hesaplar scripts/liste_grup_dokumu.py ve scripts/ab_orneklem.py dosyalarında. Kararların ve kontrollerin ayrıntılı kaydı WORKFLOW.md, reports/project_progress.md ve reports/validation/ altında.